

Desarrollo y Evaluación de un Modelo de Visión por Computadora para la Separación Inteligente de Residuos Reciclables

Autores

Lic. Fabián Andrés Uribe Guerra

Lic. Fabián Caihuara Sossa

Universidad de Buenos Aires

Facultad de Ingeniería - Buenos Aires, Argentina

Agenda

1. Descripción técnica-conceptual
2. Propósito del proyecto
3. Desafíos Clave del Conjunto de Datos TrashNet
4. Desarrollo
5. Metricas
6. Arquitectura
7. Resultados - ResNet18
8. Conclusiones ResNet18
9. Resultados - ResNet50
10. Conclusiones ResNet50
11. Cierre

Descripción técnica-conceptual

- **Objetivo:** Desarrollar un modelo de clasificación de residuos, para identificar materiales como cartón, vidrio, metal, papel, plástico y "trash" a partir de imágenes.
- **Tecnologías:** arquitecturas ResNet18 y ResNet50 pre-entrenadas
- **Motivación:** optimizar los procesos de reciclaje.
- **Impacto:** optimizar el reciclaje, reducir la contaminación y conservar recursos naturales, beneficiando el ambiente y la economía.



Propósito del proyecto





Desarrollar un modelo de ***machine learning*** que clasifique imágenes de residuos, con el fin primordial de optimizar los procesos de reciclaje y la gestión sostenible de desechos.

Desafíos Clave del Conjunto de Datos TrashNet



- Desbalance de clases
- Variabilidad en las Condiciones de Iluminación (Brillo)
- Alta Variabilidad Intra-clase
- Similitudes Inter-clase (Objetos con Apariencias Similares)



Desafíos Clave del Conjunto de Datos TrashNet

Muestras de la Clase: Cardboard



Muestras de la Clase: Glass



Muestras de la Clase: Metal



Muestras de la Clase: Paper



Muestras de la Clase: Plastic



Muestras de la Clase: Trash



Desarrollo

Tarea de clasificación multi-clase supervisada, donde el modelo debe aprender a asignar una de las predefinidas categorías de residuos (cartón, vidrio, metal, papel, plástico, o "trash" genérico) a una imagen de entrada.



Métricas

- Pérdida (Loss) (para entrenamiento y validación)
- Precisión (Accuracy) (para entrenamiento y validación)
- Precisión por Clase (Precision)
- Sensibilidad o Exhaustividad por Clase (Recall)
- Puntuación F1 por Clase (F1-Score)
- Matriz de Confusión
- Desviación Estándar de Accuracies por Clase



Arquitectura

RESNET


La clave de las ResNet son las conexiones residuales ("skip connections"), donde la entrada de un bloque (x) se suma directamente a su salida ($F(x)$), lo que se expresa como $\text{Output}=F(x)+x$.

Estas conexiones resuelven el problema del gradiente desvanecido en redes profundas, permitiendo que los gradientes fluyan mejor y facilitando que la red aprenda la función identidad. Esto hace posible entrenar modelos con muchas capas.

En redes muy profundas, es común enfrentar el problema del gradiente desvanecido (vanishing gradient), donde los gradientes se vuelven tan pequeños que no logran actualizar los pesos durante el entrenamiento. Esto impide que las redes aprendan correctamente al aumentar su profundidad.

Las conexiones residuales resuelven este problema al:

- Permitir que el gradiente fluya directamente hacia capas anteriores, sin atenuarse.
- Facilitar el aprendizaje de funciones de identidad (si el bloque no necesita modificar la información, simplemente deja pasar el input).
- Hacer posible el entrenamiento de redes mucho más profundas, como ResNet50 (con 50 capas), ResNet101 o incluso ResNet152.



ResNet18

ResNet18 es una variante ligera con 18 capas. Utiliza Bloques Básicos, que consisten en dos capas convolucionales de 3x3 con normalización por lotes y ReLU. A pesar de su menor profundidad, es eficiente y ofrece un buen rendimiento, ideal para recursos limitados.

ResNet50

ResNet50 es una arquitectura profunda con 50 capas. Utiliza Bloques Cuello de Botella (Bottleneck Blocks), que consisten en tres capas convolucionales (1x1 para reducir dimensión, 3x3, y 1x1 para restaurar). Esta configuración permite una mayor profundidad con eficiencia, logrando una capacidad de representación superior y una mayor precisión en tareas complejas.

Resultados - ResNet18

Transfer Learning

Entrenamiento sin
balanceo de datos

Entrenamiento con
balanceo de datos

Hiperparametros:



batch_size: 32
learning_rate: 0.001
num_epochs: 20
patience: 3
factor: 0.5

=====

RESULTADOS SIN BALANCEO - Accuracy por clase:

=====

cardboard: 87.06% (74/85)
glass: 70.09% (82/117)
metal: 93.75% (75/80)
paper: 77.57% (83/107)
plastic: 71.76% (63/85)
trash: 46.88% (15/32)



Resultados - ResNet18

Transfer Learning

Entrenamiento sin
balanceo de datos

Entrenamiento con
balanceo de datos

Hiperparametros:



batch_size: 32
learning_rate: 0.001
num_epochs: 20
patience: 3
factor: 0.5

=====

RESULTADOS CON BALANCEO - Accuracy por clase:

=====

cardboard: 81.18% (69/85)
glass: 63.25% (74/117)
metal: 91.25% (73/80)
paper: 45.79% (49/107)
plastic: 69.41% (59/85)
trash: 90.62% (29/32)



Resultados - ResNet18



COMPARACIÓN DE RESULTADOS

Accuracy general en validación:

Sin balanceo: 79.25%

Con balanceo: 71.94%

Diferencia: -7.31%



ANÁLISIS ESTADÍSTICO

Desviación estándar de accuracies por clase:

Sin balanceo: 14.88%

Con balanceo: 16.11%

Reducción en variabilidad: -1.23%

Clases más beneficiadas por el balanceo:

- trash: +43.75%

Clases que empeoraron con el balanceo:

- paper: -31.78%



- glass: -6.84%

- cardboard: -5.88%

- metal: -2.50%

- plastic: -2.35%

Resultados - ResNet18



Conclusiones ResNet18



El dataset TrashNet presenta desbalanceo entre clases. Sin técnicas de balanceo, el modelo tiende a favorecer las clases mayoritarias. **Las clases minoritarias tienen menor accuracy**

- Weighted sampling + weighted loss mejora el rendimiento en clases minoritarias.
- Se reduce la variabilidad entre clases (menor desviación estándar).
- Puede haber una ligera disminución en clases mayoritarias.

Resultados - ResNet18 con Data A.


Transfer Learning



Data Augmentation

Tomando en cuenta la cantidad de imágenes limitadas, se aplicará algoritmo de data augmentation para generar "nuevos" ejemplos de datos de entrenamiento.

- **Aumenta la cantidad de datos**
- **Previene overfitting**
- **Mejora la generalización**








Resultados - ResNet18 con Data A.

Early stopping triggered after 18 epochs

Mejor modelo cargado (F1-Score: 0.6756)

Historial guardado en training_history_augmented.json



Epoch 8/25

Learning Rate: 0.001000
Batch [60/64] Loss: 1.0910

Train Metrics:

Loss: 1.2120
Accuracy: 0.4468
Precision (macro): 0.5234
Precision (weighted): 0.5219
Recall (macro): 0.4432
Recall (weighted): 0.4468
F1-Score (macro): 0.4420
F1-Score (weighted): 0.4419

Validation Metrics:

Loss: 0.7910
Accuracy: 0.6798
Precision (macro): 0.7267
Precision (weighted): 0.7985
Recall (macro): 0.7243
Recall (weighted): 0.6798
F1-Score (macro): 0.6756
F1-Score (weighted): 0.7121



✓ Nuevo mejor modelo! F1-Score: 0.6756

Resultados - ResNet18 con Data A.

EVALUACIÓN FINAL DEL MODELO

MÉTRICAS FINALES EN VALIDACIÓN:

Accuracy: 0.6304
Precision (macro): 0.7175
Precision (weighted): 0.7963
Recall (macro): 0.6945
Recall (weighted): 0.6304
F1-Score (macro): 0.6294
F1-Score (weighted): 0.6558



Resultados - ResNet18 con Data A.


Clase: PAPER



Clase: TRASH



Matriz de Confusión - Modelo Final



Resultados - ResNet18 con Data A.

ANÁLISIS DETALLADO POR CLASE

Ranking de clases por F1-Score:

Clase	Precision	Recall	F1-Score	Support	Samples_Train
cardboard	0.8750	0.7500	0.8077	84	319
metal	0.6392	0.8611	0.7337	72	323
plastic	0.7684	0.6759	0.7192	108	380
glass	0.8596	0.5158	0.6447	95	407
paper	0.9556	0.3644	0.5276	118	481
trash	0.2071	1.0000	0.3432	29	111

▲ Clases con bajo rendimiento (F1 < 0.4601):
- trash

COMPARACIÓN CON BASELINE



Mejoras respecto al baseline (sin augmentation):

Accuracy: -21.96%

F1-Score: -20.06%

Precision: -12.25%

Recall: -12.55%



RESUMEN EJECUTIVO

Modelo: ResNet18 (preentrenado en ImageNet)

Dataset: TrashNet (6 clases)

Técnicas aplicadas:

- Data Augmentation fuerte (geométrico, color, ruido, distorsiones)
- Balanceo con Weighted Sampling
- Loss ponderado por frecuencia de clase
- Regularización con Dropout y Weight Decay
- Early Stopping con ReduceLRonPlateau

Resultados finales:

- Accuracy: 0.6304

- F1-Score (macro): 0.6294

- Precision (macro): 0.7175

- Recall (macro): 0.6945

Clases con mejor rendimiento:

Clase F1-Score

cardboard 0.807692

metal 0.733728

plastic 0.719212

Clases que requieren atención:

Clase F1-Score

glass 0.644737

paper 0.527607

trash 0.343195

Resultados - ResNet18 con Data A.

=====

TEST TIME AUGMENTATION (TTA)

=====

Evaluando modelo con Test Time Augmentation...

Procesando: 81/100

Resultados con TTA (subset):

Accuracy con TTA: 0.6200

=====

ANÁLISIS DE ERRORES

=====


Total de errores: 187 de 506 (36.96%)

Predicciones correctas con alta confianza (>90%): 75

Predicciones correctas con baja confianza (<60%): 99

Top 10 confusiones más frecuentes:

- paper → trash: 64 veces
- glass → metal: 20 veces
- glass → plastic: 19 veces
- cardboard → trash: 18 veces
- plastic → trash: 14 veces
- plastic → metal: 13 veces
- metal → trash: 8 veces
- plastic → glass: 8 veces
- paper → cardboard: 8 veces
- glass → trash: 7 veces



Ejemplos de Errores de Clasificación



Resultados - ResNet18 General

```
=====
TABLA COMPARATIVA FINAL
=====
```

Modelo	Accuracy	F1-Score	Precision	Recall	Técnicas
ResNet18 Baseline	0.8500	0.8300	0.8400	0.8200	Transfer Learning
ResNet18 + Aug Moderado	0.8750	0.8550	0.8600	0.8500	TL + Aug Moderado
ResNet18 + Aug Fuerte	0.6304	0.6294	0.7175	0.6945	TL + Aug Fuerte + Balanceo

Resultados - ResNet50

Data Augmentation & Rescaling

- Tomando en cuenta la cantidad de imágenes limitadas, se aplicará algoritmo de data augmentation para generar "nuevos" ejemplos de datos de entrenamiento.
- Tomar en cuenta que una red neuronal trabaja de mejor manera con valores entre 0 y 1 el Rescaling en las imágenes nos permitirá un mejor desempeño.

Características de las imágenes:

- Rescaling: Normalizar valores entre 0 y 1.
- Rotación
- Ancho Alto desplazamiento
- Zoom
- Orientacion
- Ajuste de brillo
- Variacion de canales de colores
- Relleno de pixeles faltantes


Resultados - ResNet50

Transfer Learning

El modelo aprende muy bien los datos de entrenamiento, evidenciado por la disminución de la pérdida y el aumento de la precisión.

No obstante, la pérdida de validación muestra oscilaciones, lo que sugiere inestabilidad o ruido en estos datos.

Esto indica un posible sobreajuste (overfitting) o problemas por un conjunto de validación desbalanceado/ruidoso.



- Problemas con el Dataset de Validación
- Regularización Insuficiente.
- Tamaño de Lote Reducido.
- Tasa de Aprendizaje Elevada.

Resultados - ResNet50


Transfer Learning



El ResNet50 (Transfer learning) optimizado logra una alta precisión de validación mucho más rápido, lo que demuestra los beneficios del aprendizaje por transferencia.

La disparidad entre las métricas de entrenamiento y validación es menos pronunciada que antes, lo cual es positivo.

El ResNet50 optimizado se beneficia de aprendizajes previos, lo que permite una rápida convergencia y una notable precisión de validación del 96 % en pocos periodos. Su rendimiento es superior al de la versión desarrollada desde cero, lo que resalta las ventajas del aprendizaje por transferencia.




- **Pérdida de Entrenamiento:** Disminuye rápidamente y se estabiliza tras ~10 épocas.
- **Pérdida de Validación:** Baja rápidamente a un valor menor, indicando buena convergencia.
- **Precisión de Entrenamiento:** Ascende rápido, rozando el 100%, mostrando rápida adaptación.
- **Precisión de Validación:** Logra ~96% en pocas épocas, una mejora notable.


Resultados - ResNet50



Transfer Learning



Transfer Learning



Conclusiones ResNet50



Evaluación del Modelo – Reporte de Clasificación

Resumen de métricas globales:

Métrica	Valor Actual	Valor Anterior	Mejora
Accuracy	0.94	0.88	✓ +6%
F1 Macro Average	0.94	0.87	✓ +7%
F1 Weighted Average	0.94	0.88	✓ +6%

El modelo muestra mejoras sustanciales en todas las métricas clave, reflejando una mejor generalización y adaptación al conjunto de datos gracias al uso de **Transfer Learning** y ajustes finos de la arquitectura ResNet50.

1. **Transfer Learning con ResNet50 funciona eficientemente**, incluso con un dataset de tamaño moderado.
2. **Se observa un mejor equilibrio entre precisión y recall**, lo que indica generalización adecuada.
3. La clase "trash" —antes la más débil— ha mejorado significativamente.
4. El modelo logra **resultados sólidos en todas las clases**, sin rezagos graves.

¡Muchas gracias!