

Desarrollo y Evaluación de un Modelo de Visión por Computadora para la Separación Inteligente de Residuos Reciclables

Autores

Lic. Fabián Andrés Uribe Guerra

Lic. Fabián Caihuara Sossa

Universidad de Buenos Aires

Facultad de Ingeniería - Buenos Aires, Argentina

Agenda

1. Descripción técnica-conceptual
2. Desafíos Clave del Conjunto de Datos TrashNet
3. Metricas
4. Data Augmentation
5. Arquitectura
6. Resultados - ResNet18
7. Conclusiones ResNet18
8. Resultados - ResNet50
9. Conclusiones ResNet50
10. Cierre

Descripción técnica-conceptual



- **Objetivo:** Desarrollar un modelo de clasificación de residuos, para identificar materiales como cartón, vidrio, metal, papel, plástico y "trash" a partir de imágenes.
- **Tecnologías:** arquitecturas ResNet18 y ResNet50 pre-entrenadas
- **Motivación:** optimizar los procesos de reciclaje.
- **Impacto:** optimizar el reciclaje, reducir la contaminación y conservar recursos naturales, beneficiando el ambiente y la economía.



Desafíos Clave del Conjunto de Datos TrashNet



- Desbalance de clases
- Variabilidad en las Condiciones de Iluminación (Brillo)
- Alta Variabilidad Intra-clase
- Similitudes Inter-clase (Objetos con Apariencias Similares)



Desafíos Clave del Conjunto de Datos TrashNet

El dataset está compuesto por carpetas que contienen imágenes de residuos organizadas en distintas categorías. Cada categoría incluye mayormente entre 400 y 500 imágenes en formato JPG, con una resolución de 512x384 píxeles.

Distribución por clase:

- **Basura:** 137 imágenes
- **Papel:** 594 imágenes
- **Metal:** 410 imágenes
- **Plástico:** 482 imágenes
- **Vidrio:** 501 imágenes
- **Cartón:** 403 imágenes

Muestras de la Clase: Paper



Muestras de la Clase: Plastic



Muestras de la Clase: Trash



Desafíos Clave del Conjunto de Datos TrashNet

Este problema de clasificación presenta dos desafíos clave:

- **Escasez de datos**, junto con un **desbalance en las clases**.
- **Alta semejanza visual entre imágenes de distintas categorías**, lo que puede dificultar la correcta clasificación.

Este último punto puede observarse en los ejemplos mostrados a la derecha.



Métricas


- Pérdida (Loss) (para entrenamiento y validación)
- Precisión (Accuracy) (para entrenamiento y validación)
- Precisión por Clase (Precision)
- Sensibilidad o Exhaustividad por Clase (Recall)
- Puntuación F1 por Clase (F1-Score)
- Matriz de Confusión
- Desviación Estándar de Accuracies por Clase



Para aumentar la diversidad visual del dataset se realizaron las siguientes transformaciones:

- **Rotaciones**, para representar residuos en distintas orientaciones.
- **Volteos horizontales y verticales**, simulando cómo pueden ser depositados.
- **Zoom y escalado**, para reflejar diferentes tamaños y distancias respecto a la cámara.
- **Ajustes de color y brillo**, imitando condiciones de iluminación variables (por ejemplo, interior vs. exterior).

Estas técnicas ayudaron a **reducir el *overfitting*** en los modelos entrenados, al introducir variaciones visuales sin necesidad de recolectar más datos.




Arquitectura

ResNet18

ResNet18 es una variante ligera con 18 capas. Utiliza Bloques Básicos, que consisten en dos capas convolucionales de 3x3 con normalización por lotes y ReLU. A pesar de su menor profundidad, es eficiente y ofrece un buen rendimiento, ideal para recursos limitados.

ResNet50

ResNet50 es una arquitectura profunda con 50 capas. Utiliza Bloques Cuello de Botella (Bottleneck Blocks), que consisten en tres capas convolucionales (1x1 para reducir dimensión, 3x3, y 1x1 para restaurar). Esta configuración permite una mayor profundidad con eficiencia, logrando una capacidad de representación superior y una mayor precisión en tareas complejas.



Resultados - ResNet18



Entrenamiento sin
balanceo de datos

Entrenamiento con
balanceo de datos

Hiperparametros:

batch_size: 32
learning_rate: 0.001
num_epochs: 20
patience: 3
factor: 0.5

```
=====
RESULTADOS SIN BALANCEO - Accuracy por clase:
=====
cardboard: 87.06% (74/85)
glass: 70.09% (82/117)
metal: 93.75% (75/80)
paper: 77.57% (83/107)
plastic: 71.76% (63/85)
trash: 46.88% (15/32)
```



Conclusiones ResNet18




El dataset TrashNet presenta desbalanceo entre clases. Sin técnicas de balanceo, el modelo tiende a favorecer las clases mayoritarias. **Las clases minoritarias tienen menor accuracy**

Resultados - ResNet18 con Data A.

Data Augmentation

Tomando en cuenta la cantidad de imágenes limitadas, se aplicará algoritmo de data augmentation para generar "nuevos" ejemplos de datos de entrenamiento.

- **Aumenta la cantidad de datos**
- **Previene overfitting**
- **Mejora la generalización**



Resultados - ResNet18 - Data Augmentation

Entrenamiento sin
balanceo de datos

Entrenamiento con
balanceo de datos

Distribución por clase en dataset de entrenamiento balanceado:

cardboard: 475 imágenes (16.67%)

glass: 475 imágenes (16.67%)


metal: 475 imágenes (16.67%)

paper: 475 imágenes (16.67%)

plastic: 475 imágenes (16.67%)

trash: 475 imágenes (16.67%)

Ratio de desbalanceo en dataset train balanceado:
1.00



Resultados - ResNet18

Número de imágenes en el conjunto de entrenamiento balanceado: 2850



Número de imágenes en el conjunto de validación original: 253

Número de imágenes en el conjunto de prueba original: 253



**Mejor precisión de validación:
86,96%**

Classification Report:

	precision	recall	f1-score	support
cardboard	0.97	0.83	0.89	41
glass	0.65	0.90	0.76	50
metal	0.87	0.83	0.85	41
paper	0.77	0.92	0.84	59
plastic	0.79	0.55	0.65	49
trash	1.00	0.46	0.63	13
accuracy			0.79	253
macro avg	0.84	0.75	0.77	253
weighted avg	0.81	0.79	0.79	253



Matrices - ResNet18 con y sin balanceo



Conclusiones ResNet18



Balanceo de Datos: El aumento de datos en el entrenamiento igualó las clases.

Rendimiento General: ResNet18 mejoró notablemente, alcanzando un 79% de precisión en el conjunto de prueba balanceado.

Rendimiento por Clase:

- 'Cardboard', 'metal', 'paper': Altas precisiones
- 'Plastic', 'trash': Rendimiento inferior.
- 'Trash': 100% de precisión, pero solo 46% de recall (difícil de identificar).

Resultados - ResNet50

Data Augmentation & Rescaling

- Tomando en cuenta la cantidad de imágenes limitadas, se aplicará algoritmo de data augmentation para generar "nuevos" ejemplos de datos de entrenamiento.
- Tomar en cuenta que una red neuronal trabaja de mejor manera con valores entre 0 y 1 el Rescaling en las imágenes nos permitirá un mejor desempeño.

Características de las imágenes:

- Rescaling: Normalizar valores entre 0 y 1.
- Rotación
- Ancho Alto desplazamiento
- Zoom
- Orientacion
- Ajuste de brillo
- Variacion de canales de colores
- Relleno de pixeles faltantes


Resultados - ResNet50

Transfer Learning

El modelo aprende muy bien los datos de entrenamiento, evidenciado por la disminución de la pérdida y el aumento de la precisión.

No obstante, la pérdida de validación muestra oscilaciones, lo que sugiere inestabilidad o ruido en estos datos.

Esto indica un posible sobreajuste (overfitting) o problemas por un conjunto de validación desbalanceado/ruidoso.



- Problemas con el Dataset de Validación
- Regularización Insuficiente.
- Tamaño de Lote Reducido.
- Tasa de Aprendizaje Elevada.

Resultados - ResNet50


Transfer Learning



El ResNet50 (Transfer learning) optimizado logra una alta precisión de validación mucho más rápido, lo que demuestra los beneficios del aprendizaje por transferencia.

La disparidad entre las métricas de entrenamiento y validación es menos pronunciada que antes, lo cual es positivo.

El ResNet50 optimizado se beneficia de aprendizajes previos, lo que permite una rápida convergencia y una notable precisión de validación del 96 % en pocos periodos. Su rendimiento es superior al de la versión desarrollada desde cero, lo que resalta las ventajas del aprendizaje por transferencia.

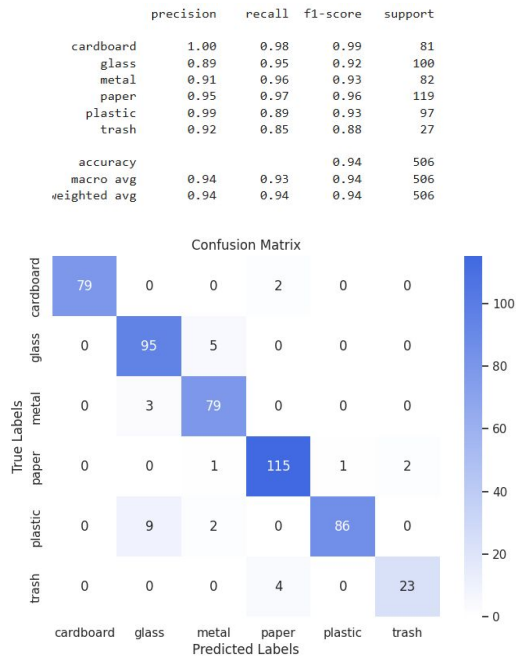


- **Pérdida de Entrenamiento:** Disminuye rápidamente y se estabiliza tras ~10 épocas.
- **Pérdida de Validación:** Baja rápidamente a un valor menor, indicando buena convergencia.
- **Precisión de Entrenamiento:** Ascende rápido, rozando el 100%, mostrando rápida adaptación.
- **Precisión de Validación:** Logra ~96% en pocas épocas, una mejora notable.

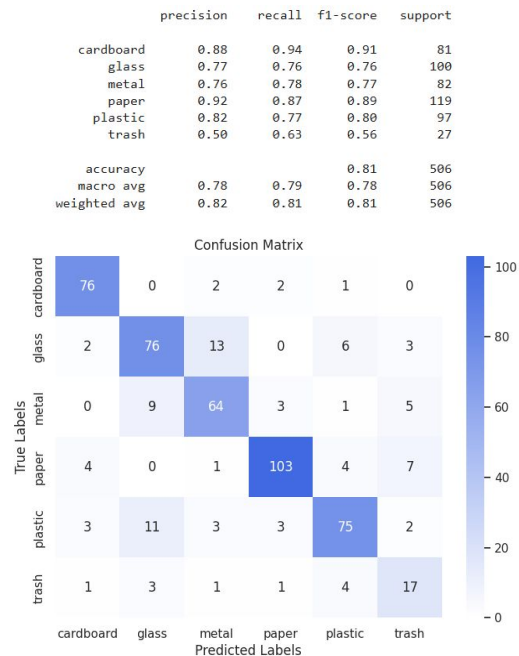
Resultados - ResNet50



Transfer Learning



Transfer Learning



Conclusiones ResNet50



Evaluación del Modelo – Reporte de Clasificación

Resumen de métricas globales:

Métrica	Valor Actual	Valor Anterior	Mejora
Accuracy	0.94	0.88	✓ +6%
F1 Macro Average	0.94	0.87	✓ +7%
F1 Weighted Average	0.94	0.88	✓ +6%

El modelo muestra mejoras sustanciales en todas las métricas clave, reflejando una mejor generalización y adaptación al conjunto de datos gracias al uso de **Transfer Learning** y ajustes finos de la arquitectura ResNet50.

1. **Transfer Learning con ResNet50 funciona eficientemente**, incluso con un dataset de tamaño moderado.
2. **Se observa un mejor equilibrio entre precisión y recall**, lo que indica generalización adecuada.
3. La clase "trash" —antes la más débil— ha mejorado significativamente.
4. El modelo logra **resultados sólidos en todas las clases**, sin rezagos graves.

¡Muchas gracias!